

Z-MAX 七模型对比 · 技术选型报告

ACT / SmoI VLA / SmoI VLA+LEW / VLA-Touch / AWE / MLP 蒸馏 / 官方专家(真值) 纵向对比

生成时间: 2026-08-07 14:23:54 · 数据源: metaworld 统一数据集 · 环境: RTX 4060 8GB

方法: 同数据集 · 同评估口径 (Scope 归一化) · 同 1000 步训练基线

1 实验概况

模型	类别	世界模型	训练吞吐	显存	状态
ACT	回归式	无	16 step/s	~2GB	
SmoI VLA	扩散式	无	2753 step/s	~5GB	
SmoI VLA+LEW	扩散式 + 世界模型	LeWorldModel	292 step/s	~7GB	
VLA-Touch	扩散式 + 触觉增强	无	25 step/s	~3GB	
AWE	场景原生 + 潜空间世界模型	zFlow	9 step/s	~3.5GB	
MLP 蒸馏	回归式	无	无数据	~0.5GB	
官方专家	规则式	无	无数据	0	规则基准 · 无训练

实验目的：为 Z-MAX 光模块插拔场景（Z700 全自主 / Z700F Fix）选型最优策略架构。七个模型在同一 metaworld 数据集上各训练 1000 步，统一评估训练收敛、推理效果与部署成本, 以数据支撑技术路线决策。

2 系统全貌 (Simulink Pipeline)

全局流程：标准数据集训练（metaworld 仿真）Sim-to-Real 迁移（影子模式验证）真机采集（Orin）上传中转（ECS）真机微调 部署推理 对比评估 报告



未提供画布 flow — 跳过拓扑明细 (可传 --flow flows/xxx. json)

3 分系统功能分析

3.1 视觉感知子系统（视觉编码）

接口：图像 视觉特征

模型	实现
ACT	ResNet18 CNN 特征图
SmoI VLA	SmoI VLM2 视觉 token
SmoI VLA+LEW	SmoI VLM2 视觉 token（参与训练）
VLA-Touch	DINOv2 嵌入
AWE	SigLIP 视触觉融合
MLP 蒸馏	—
官方专家	—

3.2 世界模型子系统（未来预测）

接口：状态/视频/潜空间 未来预测

模型	实现
ACT	无（纯反应式）
SmoI VLA	无（纯反应式）
SmoI VLA+LEW	LeWorldModel 预测下一帧
VLA-Touch	无（Interpolant 动作桥）
AWE	zFlow GRU 预测未来潜状态
MLP 蒸馏	—
官方专家	—

3.3 动作生成子系统（动作解码）

接口：特征 动作块

模型	实现
ACT	Transformer Decoder 回归
SmoI VLA	DiT-B 扩散去噪
SmoI VLA+LEW	DiT-B 扩散去噪 + LEW 调制
VLA-Touch	base VLA 动作 + Interpolant 精炼
AWE	ActionHead（未来决策交叉注意力注入）
MLP 蒸馏	—
官方专家	—

3.4 触觉/力觉子系统（触觉感知）

接口：触觉图/力觉 力信号

模型	实现
ACT	无
SmoI VLA	无
SmoI VLA+LEW	无
VLA-Touch	GelSight Marker 跟踪（模拟）
AWE	SigLIP 视触觉原生融合（模拟）
MLP 蒸馏	—
官方专家	—

3.5 训练子系统（策略学习）

接口：数据 策略权重

模型	实现
ACT	BC 回归, 50步
SmoI VLA	扩散 BC, 50步
SmoI VLA+LEW	扩散 BC + 世界模型 loss
VLA-Touch	只训 Interpolant 控制器
AWE	潜空间世界模型 + 动作头联合
MLP 蒸馏	—
官方专家	—

3.6 评估子系统（对比分析）

接口：曲线/视频 结论

模型	实现
ACT	Scope + 视频
SmoI VLA	Scope + 视频
SmoI VLA+LEW	Scope + 视频
VLA-Touch	Scope + 视频
AWE	Scope + 视频
MLP 蒸馏	—
官方专家	—

4 模块接口说明

模块	输入	输出
metaworld 数据	输入：采集数据源（metaworld 696帧/0rin 真机）	输出：states(4D) · actions(4D) · images
视觉主干 ResNet18	输入：图像 (B, C, H, W)	输出：图像特征图 (B, 512, 7, 7)
VAE 编码器 CVAE	输入：真值动作块（训练时）	输出：潜变量 (μ , $\log \sigma^2$)
Transformer Encoder	输入：latent + 图像特征 + state	输出：上下文 tokens
Transformer Decoder	输入：上下文 tokens	输出：动作块 (B, 7, 4)
Action Head 4D · ACT	输入：解码特征	输出：关节动作 (B, 7, 4)
Temporal Ensemble	输入：动作块序列	输出：时间平滑动作
SmoI VLM2-500M	输入：图像+文本指令	输出：多模态 embeds
DiT-B 动作解码	输入：多模态 embeds + 噪声	输出：去噪动作
LeWorldModel	输入：视频帧+动作	输出：预测下一帧（自监督）
DINOv2 视觉编码	输入：图像	输出：视觉嵌入（条件）
Marker 触觉跟踪	输入：GelSight 触觉图	输出：力信号 m（低维）
Interpolant 控制器	输入：VLA动作a + 视觉 + 触觉m	输出：精炼动作 $\square$
SigLIP 视触觉编码	输入：图像+力觉	输出：视触觉特征
H-JEPA 三层潜空间	输入：视触觉特征+状态	输出：z空间/z物体/z语义
zFlow 世界引擎	输入：三层潜状态+动作历史	输出：未来潜状态预测
未来决策交叉注意力	输入：解码隐层 + 未来潜状态	输出：注入动作特征（门控1.0/0.1/0.01）
训练节点	输入：数据+策略配置	输出：checkpoint (outputs/train/)
对比评估 Scope	输入：各模型曲线	输出：对比图表
推理效果对比	输入：各模型 rollout	输出：同步视频对比

5 参数对比

模型	参数量	隐层	层数	冻结策略	训练吞吐	显存
ACT	~65M (ResNet18 11M + VAE 2M + Transformer 52M)	256	4	backbone 冻结 (pretrained)	16	~2GB
SmoIVLA	~600M (VLM 500M 冻结 + DiT-B 动作头 100M 未训练部分)	256	1	SmoIVLM2 冻结	2753	~5GB
SmoIVLA+LEW	~680M (+80M 世界模型)	256	1	VLM 参与训练 (LEW 要求)	292	~7GB
VLA-Touch	~200M 增量 (DINOv2 22M 冻结 + Interpolant ~1M 轻量)	256	1	base VLA 冻结 (官方不微调)	25	~3GB
AWE	~120M 增量 (SigLIP 86M 冻结 + 潜空间/GRU/注入 ~34M)	256	1	SigLIP 冻结	9	~3.5GB
MLP 蒸馏	~0.7M (128+512 两层 MLP, outputs/rl_peg/expert_mlp.pt)	512	1	—	—	~0.5GB
官方专家	0 (系统内置, 无参数)	0	0	—	—	0

6 架构区别

维度	ACT	SmoIVLA	SmoIVLA+LEW	VLA-Touch	AWE	MLP 蒸馏	官方专家
生成方式	回归式 (deterministic regression)	扩散式 (denoising diffusion)	扩散式 + 世界模型	扩散式 + 触觉增强 (bridge 控制器)	场景原生 + 潜空间世界模型 (它石架构)	回归式 (behavior cloning MLP)	规则式 (真值基准)
世界模型	无	无	无	无	无	无	无
触觉/力觉	无	无	无	有 (模拟)	无	无	无
视觉编码	CNN	SmoIVLM2-500M	SmoIVLM2	DINOv2	SigLIP 视觉	39D 全观测编码	metaworld 内置规则策略
训练策略	backbone 冻结 (pretrained)	SmoIVLM2 冻结	VLM 参与训练 (LEW 要求)	base VLA 冻结 (官方不微调)	SigLIP 冻结	—	—

关键差异：① 生成方式 — ACT 确定性回归 vs SmoIVLA 系扩散生成 (输出分布 vs 单值);② 世界模型 — LEW (像素级预测) 与 AWE zFlow (潜空间预测) 提供预见性, ACT/SmoIVLA/VLA-Touch 为反应式;③ 触觉 — VLA-Touch (Marker 桥) 与 AWE (视触觉原生融合) 面向插拔力控;④ 架构哲学 — AWE 场景原生 (从任务倒推), 其余通用架构适配。

6.1 模型架构图 (七模型)

Z-MAX 七模型架构对比

ACT

动作分块 Transformer
(VAE 解码器)

观测: 图像+状态

编码器 4层

VAE 潜空间 32d

动作分块解码 (7步)

SmolVLA

VLM 视觉语言动作
(扩散策略)

观测: 图像+文本

SmolVLM2-500M

扩散去噪迭代

动作(连续)

SmolVLA+LEW

VLM + 世界模型
(LeWorldModel)

观测: 图像+文本

SmolVLM2-500M

GRU 世界模型 6层

未来状态预测→动作

VLA-Touch

触觉增强插值
(Interpolant)

观测: 状态+触觉

触觉编码器

Interpolant 采样

小步精炼动作

AWE-zFlow

场景原生 + 世界模型
(zFlow 三层潜空间)

观测: 状态+视触觉

三层潜空间(几何/物体/语义)

GRU 世界模型预测未来

潜空间推演→动作

MLP 蒸馏

行为克隆 MLP
(蒸馏自官方专家)

观测: 39D 完整观测

全连接 512×1

专家 BC 蒸馏 300eps

直接输出动作

官方专家

规则策略 (真值基准)
(PD 控制律+夹爪状态机)

观测: 状态+目标

PD 位置控制律

夹爪状态机

规则直算动作

7 功能分析（能力矩阵）

能力	ACT	SmoI VLA	SmoI VLA+LEW	VLA-Touch	AWE	MLP 蒸馏	官方专家
力控插拔	7/10	5/10	6/10	9/10	9/10	6/10	10/10
触觉感知	2/10	3/10	3/10	9/10	8/10	2/10	4/10
世界模型预见	3/10	4/10	8/10	5/10	8/10	3/10	5/10
多模态指令	2/10	9/10	9/10	7/10	6/10	2/10	2/10
边缘部署	9/10	5/10	4/10	8/10	8/10	10/10	10/10
长时序泛化	4/10	6/10	8/10	6/10	8/10	5/10	4/10

7.1 能力评分依据（每个能力怎么打的）

力控插拔：按插拔成功率与力控闭环能力：官方专家（规则真值，85%成功率）10/10 是目标；VLA-Touch/AWE（触觉力控原生）9；ACT（产线已量产）7；MLP 蒸馏（插入55%）6；SmoI VLA/SmoI VLA+LEW（无触觉扩散）5/6

触觉感知：架构是否原生支持触觉/力觉：VLA-Touch（GelSight Marker 桥）9；AWE（SigLIP 视触觉融合）8；官方专家（规则力控，非感知）4；其余无触觉模块 2-3

世界模型预见：是否含未来预测模块：SmoI VLA+LEW（像素级预测）8；AWE（zFlow 潜空间预测）8；官方专家（规则前瞻）5；ACT/SmoI VLA/VLA-Touch/MLP（反应式）3-4

多模态指令：视觉语言指令能力：SmoI VLA/SmoI VLA+LEW（VLM）9；VLA-Touch（视觉+触觉）7；AWE 6；ACT/MLP/专家（纯状态）2

边缘部署：参数量与采样开销（Orin 约束）：MLP/官方专家（无推理开销）10；ACT（无扩散采样）9；VLA-Touch/AWE（轻量）8；SmoI VLA（扩散需量化）5；SmoI VLA+LEW（最重）4

长时序泛化：世界模型预见+架构：SmoI VLA+LEW/AWE（世界模型）8；VLA-Touch 6；SmoI VLA 6；MLP 蒸馏（复现专家轨迹）5；ACT（确定性回归）4；官方专家（规则固定）4

8 性价比分析（开发成本 vs 收益）

成本 = 训练时间 + 显存 + 数据需求 + 调参难度；收益 = 收敛性 + 能力分 + 部署友好。

模型	训练吞吐	显存	数据需求	调参难度	收敛性(归一化)	能力综合	性价比
ACT	16	~2GB	中	低	1%	5.6	5.6
SmoI VLA	2753	~5GB	高	高	-16%	5.4	3.0
SmoI VLA+LEW	292	~7GB	很高	高	5%	4.7	2.6
VLA-Touch	25	~3GB	高	低	-48%	6.8	6.8
AWE	9	~3.5GB	中	低	94%	7.8	7.8
MLP 蒸馏	—	~0.5GB	低	高	73%	6.9	3.9
官方专家	—	0	无	高	—	6.1	3.4

性价比 = 综合评分 / (1 + 调参难度惩罚)。低成本高收益模型（ACT/VLA-Touch/AWE）适合作产线主力候选。

8.1 评分公式（每个维度怎么得到的）

综合评分 = Σ (维度得分 × 权重)，满分 10；各维度得分公式如下：


- ① 收敛性（权重20%）：min(10, 3 + 归一化下降率% ÷ 12) — 曲线前3点均值=1归一化后，末点相对首点下降百分比（降60%8分，降90%封顶10）
- ② 训练吞吐（10%）：min(10, 4 + 1.8 × log(step_s+1)) — step_s = 训练日志实测速度（步/秒）
- ③ 显存友好（10%）：max(3, 10 - 1.2 × 显存档位) — 档位：ACT 2.0 / VLA-Touch 3.0 / AWE 3.5 / SmoI VLA 5.0 / SmoI VLA+LEW 7.0（GB），反向
- ④ 世界模型（15%）：含未来预测模块 8.5 分，否则 4.5
- ⑤ 触觉/力觉（20%）：架构原生支持 9.0（VLA-Touch Marker 桥 / AWE 视触觉融合），否则 4.0 — Z-MAX 插拔力控刚需
- ⑥ 边缘部署（15%）：Orin 可部署 () 9.0，否则 5.5
- ⑦ 数据需求（5%）：低 9.0 / 中 7.5 / 高 5.5 / 很高 4.0（反向：需求越低分越高）
- ⑧ 视频证据（5%）：6.5 + (有 rollout 推理帧 +1.5)

性价比 = 综合评分 ÷ (1 + 调参难度惩罚)，惩罚：低难度 0 / 高难度 0.8。

代入示例（VLA-Touch，每项怎么得到）：①收敛 5.0=min(10, 3+归一化下降率%/12) [无曲线5.0 中性] · ②吞吐 6.5=min(10, 4+1.8 × log10(step_s+1)) [step_s=7649] · ③显存 6.4=max(3, 10-1.2 × 档位3.0GB) · ④世界模型 4.5 [无4.5] · ⑤触觉 9.0 [GelSight Marker 桥9.0] · ⑥部署 9.0 [Orin 9.0] · ⑦数据 5.5 [需求高5.5] · ⑧视频 8.0 [有 rollout8.0] 综合 6.79 = Σ (得分 × 权重)

模型	convergence 20%	world_model 15%	tactile 20%	edge 15%	throughput 10%	gpu 10%	data 5%	video_evid 5%	综合
ACT	3.1	4.5	4.0	9.0	6.2	7.6	7.5	8.0	5.61
SmoI VLA	5.0	4.5	4.0	5.5	10.0	4.0	5.5	8.0	5.38
SmoI VLA+LEW	3.4	4.5	4.0	5.5	8.4	3.0	4.0	8.0	4.72
VLA-Touch	5.0	4.5	9.0	9.0	6.5	6.4	5.5	8.0	6.79
AWE	10.0	4.5	9.0	9.0	5.8	5.8	7.5	8.0	7.76
MLP 蒸馏	9.1	4.5	4.0	9.0	5.0	9.4	9.0	8.0	6.93
官方专家	5.0	4.5	4.0	9.0	5.0	9.4	9.5	8.0	6.14

技术选型加权评分 (收敛20% · 世界模型15% · 触觉20% · 部署15% · 吞吐10% · 显存10% · 数据5% · 视频5%)




9 各模型优势与劣势（数据支撑）

9.0 关键实验：触觉中断（AWE 预测中决策 vs VLA-Touch 反应式）

指标	VLA-Touch	AWE-zFlow	胜者
初始最终距离	0.2240.218	0.2240.135	AWE
中断后距离恶化	+0.001	-0.047	AWE
动作退化	+0.006	-0.013	VLA-Touch

实验：peg-insert-side-v3 插销，前30帧真触觉30帧后触觉传感器中断。结论：VLA-Touch（触觉反应式）中断后原地踏步，AWE（世界模型预见式）靠潜空间预测接触演化继续接近 — 预测中决策优势。

模型	收敛(首末/下降)	优势	劣势	定位
ACT	1.991.96 (1%)	收敛快·曲线平滑·部署最简·确定性输出(产线一致性)	无世界模型预见性·无触觉·长时序泛化弱·对遮挡敏感	S0 已量产 (Z700 力控插入在用)
SmoIVLA	0.020.02 (~16%)	视觉语言通用·多模态指令·泛化强	无世界模型·无触觉·训练慢·显存高·输出随机性	S1 实验验证中
SmoIVLA+LEW	0.040.04 (5%)	世界模型预见性·遮挡/异常鲁棒·长时序规划	训练最慢·显存最高·收敛波动·两路 loss 叠加难调	S1 实验验证中
VLA-Touch	0.010.01 (~48%)	触觉闭环·插拔/力控精细·显存低·只训轻量模块	需真触觉数据(当前模拟)·无世界模型·依赖 base VLA 质量	S1 实验验证中 (真机 H06 力觉待接入)
AWE	0.630.04 (94%)	场景原生融合·潜空间世界模型·交叉注意力注入·力觉感知·性价比高	潜空间可解释性弱·需力觉数据·世界模型目标间接监督	S1 实验验证中 (真机力觉待接入)
MLP 蒸馏	1.650.45 (73%)	蒸馏自官方专家·39D完整观测(含peg/孔3D坐标)·训练最快·边缘最轻·抓起18/20插入11/20(55%)为学习模型最高档	插入55%<专家85%·无世界模型·无触觉·上限=专家示范质量·纯回归无多模态指令	S1 实验验证中 (对照专家真值)
官方专家	规则基准·无训练	真值锚点·成功率85%全场最高·规则可解释可审计·零训练零部署成本·所有学习模型的目标	非学习模型(不体现AI泛化)·无法适应新场景/遮挡/磨损·依赖精确状态估计·真机需规则重写	S0 参考基准 (所有学习模型的目标)



图注：左图为原始 loss 曲线（不同模型 loss 口径不同 — ACT 动作MSE 大，SmoIVLA 系扩散噪声MSE 小，绝对值不可直接横比）；右图为 Scope 归一化（前3点均值=1）后看下降斜率，为横比口径。

9.1 推理效果视频对比

模型	视频帧数	证据
ACT	60 帧	reports/rollout_act/frame_*.png
SmoIVLA	60 帧	reports/rollout_smolvla/frame_*.png
SmoIVLA+LEW	60 帧	reports/rollout_smolvla_lew/frame_*.png
VLA-Touch	60 帧	reports/rollout_vla_touch/frame_*.png
AWE	60 帧	reports/rollout_awe_zflow/frame_*.png
MLP 蒸馏	60 帧	reports/rollout_expert_mlp/frame_*.png

模型	视频帧数	证据
官方专家	60 帧	reports/rollout_expert_policy/frame_*.png

结论（数据支撑）：综合评分 AWE 最高（7.8/10）。训练收敛（归一化下降率）：AWE 94%、MLP 蒸馏 73%、SmoIVLA+LEW 5%、ACT 1%、SmoIVLA -16%、VLA-Touch -48%。AWE 以场景原生视触觉 + 潜空间世界模型在收敛性/触觉/部署三维度均衡领先,适合作为 Z700 下一代主力路线；ACT 保持产线兜底（确定性输出）,VLA-Touch 待真机 H06 力觉接入后复评（当前触觉为模拟）。

10 理论分析（公式 · 推导 · 证明）

从理论上论证各模型架构的优劣 — 每个模型给出核心损失/预测公式 + 定理 + 证明。理论结论与第 9.0 节触觉中断实验相互印证。

10.1 ACT — 确定性动作分块

ACT — 确定性动作分块 (条件VAE)

$$\mathcal{L}_{ACT} = \mathbb{E}[-\log p_{\theta}(a|x, z)] + \beta D_{KL}(q_{\phi}(z|x, a) \| p(z))$$

【含义】含义: 编码器把「看到什么(x)+要做什么(a)」压缩成潜变量z, 解码器再从z还原动作a。第一项=动作重建误差, 第二项=潜变量不跑偏的约束。

【比喻】比喻: 像「抄作业」——先记住要点(z), 再凭要点默写动作。训练越久, 默写越准。

【证明】证明(形象): β 越大→越强迫z只记关键信息→模型退化成「直接回归」: 看到x就输出最可能的动作(平均值)。所以 ACT 最优解=条件期望 $\mathbb{E}[a|x]$, 速度最快但只会一种答案。

10.2 SmoIVLA — VLM扩散策略

SmoIVLA — VLM 扩散策略 (DDPM)

$$\mathcal{L} = \mathbb{E}_{t, \epsilon} \|\epsilon - \epsilon_{\theta}(x_t, \text{VLM}(x), t)\|^2$$

【含义】含义: 把动作当「照片」, 训练时往照片加噪变雪花, 再教模型从雪花还原照片。x_t=加噪到第t步的图, ϵ =噪声, 模型学的是「去噪方向」。

【比喻】比喻: 像「雾里看花」——先学会从浓雾(纯噪声)里一步步看清花(动作)。每次去噪都是小步修正。

【证明】证明(形象): 每步去噪=在「动作分布」上走一步, 走很多步(约10步)后到达的终点=按真实概率采样。所以 SmoIVLA 能输出「多种正确答案」(多模态), 但每步都慢(延迟高)。

10.3 SmoIVLA+LEW — 世界模型

SmoIVLA+LEW — 世界模型 (LeWorldModel)

$$z_{t+1} = f_{WM}(z_t, a_t), \quad |J(\pi) - J^*| \leq \frac{2\gamma\epsilon}{1-\gamma}$$

【含义】含义: 世界模型学习「世界怎么变」——给定当前状态z_t和动作a_t, 预测下一状态z_{t+1}。上界公式说: 世界模型预测误差 ϵ , 经过折扣 γ 累积后, 策略性能损失有上限。

【比喻】比喻: 像「下棋想三步」——先在大脑里模拟走法后果, 再选最好的走。想得越准(ϵ 小), 棋下得越好。

【证明】证明(形象): 每步预测误差 ϵ 像「滚雪球」, 但折扣 γ 让雪球越滚越小($\gamma < 1$), 无穷级数求和= $\epsilon/(1-\gamma)$ 。模型内模拟代替真机试错→省大量真机数据(样本效率高)。

10.4 VLA-Touch — 触觉Interpolant

VLA-Touch — 触觉增强 Interpolant

$$x_t = (1 - t)x_0 + tx_1 + \gamma \mathcal{N}(0, 1), \quad \text{Var}(a|x, \tau) < \text{Var}(a|x)$$

【含义】含义: 在「纯噪声x0」和「目标动作x1」之间插值采样, 逐步逼近目标。下面的方差不等式: 加了触觉τ后, 动作的不确定性变小(知道用力大小→插得更准)。

【比喻】比喻: 像「摸黑插插头」——手摸到插座位置(触觉τ)后, 就不用瞎猜了, 一插一个准。

【证明】证明(形象): 方差分解: 总不确定性 = 知道触觉后的残余 + 触觉带来的信息量。触觉给的信息越多(互信息大), 残余不确定性越小。所以 触觉越准 → 动作误差越小。

10.5 AWE-zFlow — 潜空间世界模型

AWE-zFlow — 场景原生 + 潜空间世界模型

$$z_{t+1} = f_{GRU}(z_t^{(1)}, z_t^{(2)}, z_t^{(3)}, a_t), \quad \text{Regret} \leq \frac{2\gamma^N R_{max}}{1-\gamma} + \frac{2\gamma \epsilon_{WM}}{1-\gamma}$$

【含义】含义: 三层潜空间各管一事(几何/物体/语义), GRU世界模型预测未来; 遗憾上界=预测N步后, 未来折扣奖励被覆盖(第一项→0), 只剩世界模型误差(第二项)。

【比喻】比喻: 像「老司机开车」——不只盯眼前(反应式), 而是预判前方路况(世界模型预测), 提前打方向。触觉坏了也不慌, 凭预判继续开。

【证明】证明(形象): ①分层=把世界拆成3个抽屉各放一类信息, 互不干扰→预测更准(条件熵下降) ②预测N步=把未来N步的奖励提前算清, N越大越接近完美 ③触觉中断实验实测: VLA-Touch原地停, AWE靠预测继续接近——理论与实验互相印证。

10.6 理论综合结论

维度	ACT	SmolVLA	LEW	VLA-Touch	AWE-zFlow
预见性	无	无	像素级	无	潜空间级
触觉利用	无	无	无	有	有
理论MSE	高	中	中	低	低
延迟	O(1)	O(K)	O(K) +	O(K)	O(1)+WM
样本复杂度	高	高	中	中	低

理论优选：光模块插拔（长程+力控+多阶段）场景，AWE-zFlow 因 ①世界模型预见（定理3/6 遗憾上界最小）②触觉融合（定理4）③潜空间分层加速（定理5）综合最优；VLA-Touch 纯力控环节 MSE 理论最优；ACT 延迟敏感+简单任务占优。