

# Z-MAX 五模型对比 · 技术选型报告

ACT / SmolVLA / SmolVLA+LEW / VLA-Touch / AWE 纵向对比

生成时间: 2026-08-06 05:39:51 · 数据源: metaworld 统一数据集 · 环境: RTX 4060 8GB

方法: 同数据集 · 同评估口径 (Scope 归一化) · 同 50 步训练基线

# 1 实验概况

| 模型          | 类别             | 世界模型           | 训练吞吐        | 显存     | 状态     |
|-------------|----------------|----------------|-------------|--------|--------|
| ACT         | 回归式            | 无              | 7 step/s    | ~2GB   | □      |
| SmoIVLA     | 扩散式            | 无              | 423 step/s  | ~5GB   | □      |
| SmoIVLA+LEW | 扩散式 + 世界模型     | □ LeWorldModel | 2191 step/s | ~7GB   | □      |
| VLA-Touch   | 扩散式 + 触觉增强     | 无              | 34 step/s   | ~3GB   | □□ 无曲线 |
| AWE         | 场景原生 + 潜空间世界模型 | □ zFlow        | 15 step/s   | ~3.5GB | □      |

实验目的: 为 Z-MAX 光模块插拔场景 (Z700 全自主 / Z700F Fix) 选型最优策略架构。五个模型在同一 metaworld 数据集上各训练 50 步, 统一评估训练收敛、推理效果与部署成本,以数据支撑技术路线决策。

## 2 系统全貌 (Simulink Pipeline)

全局流程: 数据采集 → 视觉感知 → 世界模型(可选) → 动作生成 → 训练 → 对比评估 → 推理视频 → PDF 报告

□□ 未提供画布 flow — 跳过拓扑明细 (可传 --flow flows/xxx.json)

### 3 分系统功能分析

#### 3.1 视觉感知子系统 (视觉编码)

接口: 图像 → 视觉特征

| 模型          | 实现                       |
|-------------|--------------------------|
| ACT         | ResNet18 CNN 特征图         |
| SmolVLA     | SmolVLM2 视觉 token        |
| SmolVLA+LEW | SmolVLM2 视觉 token (参与训练) |
| VLA-Touch   | DINOv2 嵌入                |
| AWE         | SigLIP 视触觉融合             |

#### 3.2 世界模型子系统 (未来预测)

接口: 状态/视频/潜空间 → 未来预测

| 模型          | 实现                  |
|-------------|---------------------|
| ACT         | 无 (纯反应式)            |
| SmolVLA     | 无 (纯反应式)            |
| SmolVLA+LEW | LeWorldModel 预测下一帧  |
| VLA-Touch   | 无 (Interpolant 动作桥) |
| AWE         | zFlow GRU 预测未来潜状态   |

#### 3.3 动作生成子系统 (动作解码)

接口: 特征 → 动作块

| 模型          | 实现                           |
|-------------|------------------------------|
| ACT         | Transformer Decoder 回归       |
| SmolVLA     | DiT-B 扩散去噪                   |
| SmolVLA+LEW | DiT-B 扩散去噪 + LEW 调制          |
| VLA-Touch   | base VLA 动作 + Interpolant 精炼 |
| AWE         | ActionHead (未来决策交叉注意力注入)     |

#### 3.4 触觉/力觉子系统 (触觉感知)

接口: 触觉图/力觉 → 力信号

| 模型          | 实现                      |
|-------------|-------------------------|
| ACT         | 无                       |
| SmolVLA     | 无                       |
| SmolVLA+LEW | 无                       |
| VLA-Touch   | GelSight Marker 跟踪 (模拟) |
| AWE         | SigLIP 视触觉原生融合 (模拟)     |

#### 3.5 训练子系统 (策略学习)

接口: 数据 → 策略权重

| 模型          | 实现                 |
|-------------|--------------------|
| ACT         | BC 回归, 50步         |
| SmolVLA     | 扩散 BC, 50步         |
| SmolVLA+LEW | 扩散 BC + 世界模型 loss  |
| VLA-Touch   | 只训 Interpolant 控制器 |
| AWE         | 潜空间世界模型 + 动作头联合    |

### 3.6 评估子系统 (对比分析)

接口: 曲线/视频 → 结论

| 模型          | 实现         |
|-------------|------------|
| ACT         | Scope + 视频 |
| SmoIVLA     | Scope + 视频 |
| SmoIVLA+LEW | Scope + 视频 |
| VLA-Touch   | Scope + 视频 |
| AWE         | Scope + 视频 |

## 4 模块接口说明

| 模块                     | 输入                                 | 输出                                    |
|------------------------|------------------------------------|---------------------------------------|
| □ metaworld 数据         | 输入: 采集数据源 (metaworld 696帧/Orin 真机) | 输出: states(4D) · actions(4D) · images |
| □ 视觉主干 ResNet18        | 输入: 图像 (B,C,H,W)                   | 输出: 图像特征图 (B,512,7,7)                 |
| □ VAE 编码器 CVAE         | 输入: 真值动作块 (训练时)                    | 输出: 潜变量 ( $\mu$ , $\log\sigma^2$ )    |
| □ Transformer Encoder  | 输入: latent + 图像特征 + state          | 输出: 上下文 tokens                        |
| □ Transformer Decoder  | 输入: 上下文 tokens                     | 输出: 动作块 (B,7,4)                       |
| □ Action Head 4D · ACT | 输入: 解码特征                           | 输出: 关节动作 (B,7,4)                      |
| □ Temporal Ensemble    | 输入: 动作块序列                          | 输出: 时间平滑动作                            |
| □ SmolVLM2-500M        | 输入: 图像+文本指令                        | 输出: 多模态 embeds                        |
| □ DiT-B 动作解码           | 输入: 多模态 embeds + 噪声                | 输出: 去噪动作                              |
| □ LeWorldModel         | 输入: 视频帧+动作                         | 输出: 预测下一帧 (自监督)                       |
| □ DINOv2 视觉编码          | 输入: 图像                             | 输出: 视觉嵌入 (条件)                         |
| □ Marker 触觉跟踪          | 输入: GelSight 触觉图                   | 输出: 力信号 m (低维)                        |
| □ Interpolant 控制器      | 输入: VLA动作a + 视觉 + 触觉m              | 输出: 精炼动作 $\hat{a}$                    |
| □ SigLIP 视触觉编码         | 输入: 图像+力觉                          | 输出: 视触觉特征                             |
| □ H-JEPA 三层潜空间         | 输入: 视触觉特征+状态                       | 输出: z□空间/z□物体/z□语义                    |
| □ zFlow 世界引擎           | 输入: 三层潜状态+动作历史                     | 输出: 未来潜状态预测                           |
| □ 未来决策交叉注意力            | 输入: 解码隐层 + 未来潜状态                   | 输出: 注入动作特征 (门控1.0/0.1/0.01)           |
| □ 训练节点                 | 输入: 数据+策略配置                        | 输出: checkpoint (outputs/train/)       |
| □ 对比评估 Scope           | 输入: 各模型曲线                          | 输出: 对比图表                              |
| □ 推理效果对比               | 输入: 各模型 rollout                    | 输出: 同步视频对比                            |

5 参数对比

| 模型          | 参数量                                              | 隐层  | 层数 | 冻结策略                     | 训练吞吐 | 显存     |
|-------------|--------------------------------------------------|-----|----|--------------------------|------|--------|
| ACT         | ~65M (ResNet18 11M + VAE 20M + Transformer 52M)  | 256 | 7  | Backbone 冻结 (pretrained) | 7    | ~2GB   |
| SmolVLA     | ~600M (VLM 500M 冻结 + DiT256动作头 100M 未训练部分)       | 256 | 1  | 部分 VLM2 冻结               | 423  | ~5GB   |
| SmolVLA+LEW | ~680M (+80M 世界模型)                                | 256 | 1  | VLM 参与训练 (LEW 要求)        | 2191 | ~7GB   |
| VLA-Touch   | ~200M 增量 (DINOv2 22M 冻结 + 56 Interpolant ~1M 增量) | 256 | 1  | 轻量 VLA 冻结 (官方不微调)        | 34   | ~3GB   |
| AWE         | ~120M 增量 (SigLIP 86M 冻结 + 56 潜空间/GRU/注入 ~34M)    | 256 | 1  | SigLIP 冻结                | 15   | ~3.5GB |

## 6 架构区别

| 维度    | ACT                            | SmolVLA                   | SmolVLA+LEW       | VLA-Touch              | AWE                  |
|-------|--------------------------------|---------------------------|-------------------|------------------------|----------------------|
| 生成方式  | 回归式 (deterministic regression) | 扩散式 (denoising diffusion) | 扩散式 + 世界模型        | 扩散式 + 触觉增强 (bridge 控制) | 扩散式 + 潜空间世界模型 (它石架构) |
| 世界模型  | 无                              | 无                         | 无                 | 无                      | 有                    |
| 触觉/力觉 | 无                              | 无                         | 无                 | 有(模拟)                  | 无                    |
| 视觉编码  | CNN                            | SmolVLM2-500M             | SmolVLM2          | DINOv2                 | SigLIP视觉             |
| 训练策略  | backbone 冻结 (pretrained)       | SmolVLM2 冻结               | VLM 参与训练 (LEW 要求) | base VLA 冻结 (官方不微调)    | SigLIP 冻结            |

关键差异: ① 生成方式 — ACT 确定性回归 vs SmolVLA 系扩散生成 (输出分布 vs 单值);② 世界模型 — LEW (像素级预测) 与 AWE zFlow (潜空间预测) 提供预见性, ACT/SmolVLA/VLA-Touch 为反应式;③ 触觉 — VLA-Touch (Marker 桥) 与 AWE (视触觉原生融合) 面向插拔力控;④ 架构哲学 — AWE 场景原生 (从任务倒推), 其余通用架构适配。



## 7 功能分析 (能力矩阵)

| 能力     | ACT  | SmolVLA | SmolVLA+LEW | VLA-Touch | AWE  |
|--------|------|---------|-------------|-----------|------|
| 力控插拔   | 7/10 | 5/10    | 6/10        | 9/10      | 9/10 |
| 触觉感知   | 2/10 | 3/10    | 3/10        | 9/10      | 8/10 |
| 世界模型预见 | 3/10 | 4/10    | 8/10        | 5/10      | 8/10 |
| 多模态指令  | 2/10 | 9/10    | 9/10        | 7/10      | 6/10 |
| 边缘部署   | 9/10 | 5/10    | 4/10        | 8/10      | 8/10 |
| 长时序泛化  | 4/10 | 6/10    | 8/10        | 6/10      | 8/10 |


评分依据: 力控/触觉能力看架构是否原生支持 (VLA-Touch Marker 桥 / AWE 视触觉融合);世界模型预见看是否含未来预测模块;边缘部署看参数量与采样开销 (扩散系需量化)。

## 8 性价比分析 (开发成本 vs 收益)

成本 = 训练时间 + 显存 + 数据需求 + 调参难度; 收益 = 收敛性 + 能力分 + 部署友好。


| 模型          | 训练吞吐 | 显存     | 数据需求 | 调参难度 | 收敛性(归一化) | 能力综合 | 性价比 |
|-------------|------|--------|------|------|----------|------|-----|
| ACT         | 7    | ~2GB   | 中    | 低    | 91%      | 6.9  | 6.9 |
| SmolVLA     | 423  | ~5GB   | 高    | 高    | 63%      | 5.9  | 3.3 |
| SmolVLA+LEW | 2191 | ~7GB   | 很高   | 高    | 56%      | 5.7  | 3.2 |
| VLA-Touch   | 34   | ~3GB   | 高    | 低    | —        | 6.8  | 6.8 |
| AWE         | 15   | ~3.5GB | 中    | 低    | 96%      | 6.8  | 6.8 |

性价比 = 综合评分 / (1 + 调参难度惩罚)。低成本高收益模型 (ACT/VLA-Touch/AWE) 适合作产线主力候选。



9 各模型优势与劣势 (数据支撑)


| 模型          | 收敛(首→末/下降)       | 优势                                                    | 劣势                                     | 定位 |
|-------------|------------------|-------------------------------------------------------|----------------------------------------|----|
| ACT         | 80.48→7.26 (91%) | 收敛快·曲线平滑·部署极简·确定性输出                                   | 无世界模型·预见性·无触觉·长时序泛化弱·50步收敛·700 力控插入在用) |    |
| SmoIVLA     | 1.20→0.45 (63%)  | 视觉语言通用·多模态指令·泛化强                                      | 无世界模型·无触觉·训练慢·显存高·输出随机·验证中             |    |
| SmoIVLA+LEW | 1.17→0.52 (56%)  | 世界模型·预见性·遮挡/异常鲁棒·长时序稳健                                | 训练慢·显存最高·收敛波动·两路 loss 叠加·验证中           |    |
| VLA-Touch   | 无曲线数据            | 触觉闭环·插拔/力控精细·显存低·只训练·需要触觉数据(当前模拟)                     | 无世界模型·依赖实验VLA中质量机 H06 力觉待接入)           |    |
| AWE         | 0.63→0.03 (96%)  | 场景原生融合·潜空间世界模型·交叉注意力·可解释·推理能力优·数据·世界模型·训练验证中(真机力觉待接入) |                                        |    |



图注: 左图为原始 loss 曲线 (不同模型 loss 口径不同 — ACT 动作MSE 大, SmoIVLA 系扩散噪声MSE 小,绝对值不可直接横比); 右图为 Scope 归一化 (前3点均值=1) 后看下降斜率, 为横比口径。

9.1 推理效果视频对比

| 模型          | 视频帧数 | 证据                                      |
|-------------|------|-----------------------------------------|
| ACT         | 60 帧 | reports/rollout_act/frame_*.png         |
| SmoIVLA     | 60 帧 | reports/rollout_smolvla/frame_*.png     |
| SmoIVLA+LEW | 60 帧 | reports/rollout_smolvla_lew/frame_*.png |
| VLA-Touch   | 60 帧 | reports/rollout_vla_touch/frame_*.png   |
| AWE         | 60 帧 | reports/rollout_awe_zflow/frame_*.png   |



上图各模型 rollout 首帧对比 (同一场景 push-v3)。完整视频请在控制台「☐ 视频对比」节点双击播放。

结论 (数据支撑): 综合评分 ACT 最高 (6.9/10)。训练收敛 (归一化下降率): AWE 96%、ACT 91%、SmoIVLA 63%、SmoIVLA+LEW 56%。ACT 以确定性与部署极简领先, 但无世界模型/触觉, 建议作为产线基线;中长期向 AWE/VLA-Touch 方向演进 (力控+预见性)。