

Z-MAX 五模型对比 · 技术选型报告

ACT / SmolVLA / SmolVLA+LEW / VLA-Touch / AWE 纵向对比

生成时间: 2026-08-06 06:09:07 · 数据源: metaworld 统一数据集 · 环境: RTX 4060 8GB

方法: 同数据集 · 同评估口径 (Scope 归一化) · 同 50 步训练基线


1 实验概况

模型	类别	世界模型	训练吞吐	显存	状态
ACT	回归式	无	7 step/s	~2GB	□
SmoIVLA	扩散式	无	423 step/s	~5GB	□
SmoIVLA+LEW	扩散式 + 世界模型	□ LeWorldModel	2191 step/s	~7GB	□
VLA-Touch	扩散式 + 触觉增强	无	35 step/s	~3GB	□□ 无曲线
AWE	场景原生 + 潜空间世界模型	□ zFlow	无数据	~3.5GB	□□ 无曲线

实验目的: 为 Z-MAX 光模块插拔场景 (Z700 全自主 / Z700F Fix) 选型最优策略架构。五个模型在同一 metaworld 数据集上各训练 50 步, 统一评估训练收敛、推理效果与部署成本,以数据支撑技术路线决策。

2 系统全貌 (Simulink Pipeline)

全局流程: 数据采集 → 视觉感知 → 世界模型(可选) → 动作生成 → 训练 → 对比评估 → 推理视频 → PDF 报告



 未提供画布 flow — 跳过拓扑明细 (可传 --flow flows/xxx.json)

3 分系统功能分析

3.1 视觉感知子系统 (视觉编码)

接口: 图像 → 视觉特征

模型	实现
ACT	ResNet18 CNN 特征图
SmoIVLA	SmoIVLM2 视觉 token
SmoIVLA+LEW	SmoIVLM2 视觉 token (参与训练)
VLA-Touch	DINOv2 嵌入
AWE	SigLIP 视触觉融合

3.2 世界模型子系统 (未来预测)

接口: 状态/视频/潜空间 → 未来预测

模型	实现
ACT	无 (纯反应式)
SmoIVLA	无 (纯反应式)
SmoIVLA+LEW	LeWorldModel 预测下一帧
VLA-Touch	无 (Interpolant 动作桥)
AWE	zFlow GRU 预测未来潜状态

3.3 动作生成子系统 (动作解码)

接口: 特征 → 动作块

模型	实现
ACT	Transformer Decoder 回归
SmoIVLA	DiT-B 扩散去噪
SmoIVLA+LEW	DiT-B 扩散去噪 + LEW 调制
VLA-Touch	base VLA 动作 + Interpolant 精炼
AWE	ActionHead (未来决策交叉注意力注入)

3.4 触觉/力觉子系统 (触觉感知)

接口: 触觉图/力觉 → 力信号

模型	实现
ACT	无
SmoIVLA	无
SmoIVLA+LEW	无
VLA-Touch	GelSight Marker 跟踪 (模拟)
AWE	SigLIP 视触觉原生融合 (模拟)

3.5 训练子系统 (策略学习)

接口: 数据 → 策略权重

模型	实现
ACT	BC 回归, 50步
SmoIVLA	扩散 BC, 50步
SmoIVLA+LEW	扩散 BC + 世界模型 loss
VLA-Touch	只训 Interpolant 控制器
AWE	潜空间世界模型 + 动作头联合

3.6 评估子系统 (对比分析)

接口: 曲线/视频 → 结论

模型	实现
ACT	Scope + 视频
SmolVLA	Scope + 视频
SmolVLA+LEW	Scope + 视频
VLA-Touch	Scope + 视频
AWE	Scope + 视频

4 模块接口说明

模块	输入	输出
□ metaworld 数据	输入: 采集数据源 (metaworld 696帧/Orin 真机)	输出: states(4D) · actions(4D) · images
□ 视觉主干 ResNet18	输入: 图像 (B,C,H,W)	输出: 图像特征图 (B,512,7,7)
□ VAE 编码器 CVAE	输入: 真值动作块 (训练时)	输出: 潜变量 (μ , $\log\sigma^2$)
□ Transformer Encoder	输入: latent + 图像特征 + state	输出: 上下文 tokens
□ Transformer Decoder	输入: 上下文 tokens	输出: 动作块 (B,7,4)
□ Action Head 4D · ACT	输入: 解码特征	输出: 关节动作 (B,7,4)
□ Temporal Ensemble	输入: 动作块序列	输出: 时间平滑动作
□ SmolVLM2-500M	输入: 图像+文本指令	输出: 多模态 embeds
□ DiT-B 动作解码	输入: 多模态 embeds + 噪声	输出: 去噪动作
□ LeWorldModel	输入: 视频帧+动作	输出: 预测下一帧 (自监督)
□ DINOv2 视觉编码	输入: 图像	输出: 视觉嵌入 (条件)
□ Marker 触觉跟踪	输入: GelSight 触觉图	输出: 力信号 m (低维)
□ Interpolant 控制器	输入: VLA动作a + 视觉 + 触觉m	输出: 精炼动作 $\hat{a}$
□ SigLIP 视触觉编码	输入: 图像+力觉	输出: 视触觉特征
□ H-JEPA 三层潜空间	输入: 视触觉特征+状态	输出: z□空间/z□物体/z□语义
□ zFlow 世界引擎	输入: 三层潜状态+动作历史	输出: 未来潜状态预测
□ 未来决策交叉注意力	输入: 解码隐层 + 未来潜状态	输出: 注入动作特征 (门控1.0/0.1/0.01)
□ 训练节点	输入: 数据+策略配置	输出: checkpoint (outputs/train/)
□ 对比评估 Scope	输入: 各模型曲线	输出: 对比图表
□ 推理效果对比	输入: 各模型 rollout	输出: 同步视频对比

5 参数对比

模型	参数量	隐层	层数	冻结策略	训练吞吐	显存
ACT	~65M (ResNet18 11M + VAE 20M + Transformer 52M)	256	7	Backbone 冻结 (pretrained)	7	~2GB
SmolVLA	~600M (VLM 500M 冻结 + DiT256动作头 100M 未训练部分)	256	1	部分 VLM2 冻结	423	~5GB
SmolVLA+LEW	~680M (+80M 世界模型)	256	1	VLM 参与训练 (LEW 要求)	2191	~7GB
VLA-Touch	~200M 增量 (DINOv2 22M 冻结 + 56 Interpolant ~1M 增量)	256	1	轻量 VLA 冻结 (官方不微调)	35	~3GB
AWE	~120M 增量 (SigLIP 86M 冻结 + 56 增量空间/GRU/注入 ~34M)	256	1	SigLIP 冻结	—	~3.5GB

6 架构区别

维度	ACT	SmolVLA	SmolVLA+LEW	VLA-Touch	AWE
生成方式	回归式 (deterministic regression)	扩散式 (denoising diffusion)	扩散式 + 世界模型	扩散式 + 触觉增强 (bridge 控制)	扩散式 + 潜空间世界模型 (它石架构)
世界模型	无	无	无	无	有
触觉/力觉	无	无	无	有(模拟)	无
视觉编码	CNN	SmolVLM2-500M	SmolVLM2	DINOv2	SigLIP视觉
训练策略	backbone 冻结 (pretrained)	SmolVLM2 冻结	VLM 参与训练 (LEW 要求)	base VLA 冻结 (官方不微调)	SigLIP 冻结

关键差异: ① 生成方式 — ACT 确定性回归 vs SmolVLA 系扩散生成 (输出分布 vs 单值);② 世界模型 — LEW (像素级预测) 与 AWE zFlow (潜空间预测) 提供预见性, ACT/SmolVLA/VLA-Touch 为反应式;③ 触觉 — VLA-Touch (Marker 桥) 与 AWE (视触觉原生融合) 面向插拔力控;④ 架构哲学 — AWE 场景原生 (从任务倒推), 其余通用架构适配。

6.1 模型架构图

Z-MAX 123456789

ACT

12345 Transformer
(VAE 6789)

12: 34+5



678 90



VAE 1234



5678901(2)

SmoIVLA

VLM 12345678
(901234)

56: 78+9



SmoVLM2



1234567



89(01)

SmoIVLA+LEW

VLM + 12345
(LeWorldModel)

67: 89+0



SmoVLM2



GRU 1234



567890+1

VLA-Touch

12345678
(Interpolant)

90: 12+3



45678



Interpol



901234

AWE-zFlow

12345 + 6789
(zFlow 012345)

67: 89+0



123456(78)



GRU 1234



567890+1

7 功能分析 (能力矩阵)

能力	ACT	SmolVLA	SmolVLA+LEW	VLA-Touch	AWE
力控插拔	7/10	5/10	6/10	9/10	9/10
触觉感知	2/10	3/10	3/10	9/10	8/10
世界模型预见	3/10	4/10	8/10	5/10	8/10
多模态指令	2/10	9/10	9/10	7/10	6/10
边缘部署	9/10	5/10	4/10	8/10	8/10
长时序泛化	4/10	6/10	8/10	6/10	8/10


评分依据: 力控/触觉能力看架构是否原生支持 (VLA-Touch Marker 桥 / AWE 视触觉融合);世界模型预见看是否含未来预测模块;边缘部署看参数量与采样开销 (扩散系需量化)。

8 性价比分析 (开发成本 vs 收益)

成本 = 训练时间 + 显存 + 数据需求 + 调参难度; 收益 = 收敛性 + 能力分 + 部署友好。


模型	训练吞吐	显存	数据需求	调参难度	收敛性(归一化)	能力综合	性价比
ACT	7	~2GB	中	低	91%	6.9	6.9
SmolVLA	423	~5GB	高	高	63%	5.9	3.3
SmolVLA+LEW	2191	~7GB	很高	高	56%	5.7	3.2
VLA-Touch	35	~3GB	高	低	—	6.8	6.8
AWE	—	~3.5GB	中	低	—	5.7	5.7

性价比 = 综合评分 / (1 + 调参难度惩罚)。低成本高收益模型 (ACT/VLA-Touch/AWE) 适合作产线主力候选。



9 各模型优势与劣势 (数据支撑)


模型	收敛(首→末/下降)	优势	劣势	定位
ACT	80.48→7.26 (91%)	收敛快·曲线平滑·部署极简·确定性输出	无世界模型·预见性·无触觉·长时序泛化弱·50步收敛慢	50步收敛慢·700 力控插入在用)
SmoIVLA	1.20→0.45 (63%)	视觉语言通用·多模态指令·泛化强	无世界模型·无触觉·训练慢·显存高·输出随机	随机性验证中
SmoIVLA+LEW	1.17→0.52 (56%)	世界模型·预见性·遮挡/异常鲁棒·长时序收敛快	训练慢·显存最高·收敛波动·两路 loss 叠加	验证中
VLA-Touch	无曲线数据	触觉闭环·插拔/力控精细·显存低·只训练视觉	需要触觉数据(当前模拟)·无世界模型·依赖实验设备	实验设备 H06 力觉待接入)
AWE	无曲线数据	场景原生融合·潜空间世界模型·交叉注意力可解耦	需要触觉数据·世界模型训练慢	实验设备(真机力觉待接入)



图注: 左图为原始 loss 曲线 (不同模型 loss 口径不同 — ACT 动作MSE 大, SmoIVLA 系扩散噪声MSE 小,绝对值不可直接横比); 右图为 Scope 归一化 (前3点均值=1) 后看下降斜率, 为横比口径。

9.1 推理效果视频对比

模型	视频帧数	证据
ACT	60 帧	reports/rollout_act/frame_*.png
SmoIVLA	60 帧	reports/rollout_smolvla/frame_*.png
SmoIVLA+LEW	60 帧	reports/rollout_smolvla_lew/frame_*.png
VLA-Touch	60 帧	reports/rollout_vla_touch/frame_*.png
AWE	60 帧	reports/rollout_awe_zflow/frame_*.png



上图各模型 rollout 首帧对比 (同一场景 push-v3)。完整视频请在控制台「□ 视频对比」节点双击播放。

结论 (数据支撑): 综合评分 ACT 最高 (6.9/10)。训练收敛 (归一化下降率): ACT 91%、SmoIVLA 63%、SmoIVLA+LEW 56%。ACT 以确定性与部署极简领先, 但无世界模型/触觉, 建议作为产线基线;中长期向 AWE/VLA-Touch 方向演进 (力控+预见性)。